



Université Alioune Diop
L'Excellence est ma constance, l'Éthique ma vertu !

DÉTECTION AUTOMATIQUE DU PALUDISME PAR DEEP LEARNING

Classification d'images de cellules sanguines
par réseaux de neurones convolutifs

Papa Malick NDIAYE

Master Data Science et Génie Logiciel

Université Alioune Diop de Bambey

Année académique 2024-2025

Démonstration en ligne : <https://deep-learning-malaria-detection-znf2.onrender.com/>

Code source : https://github.com/pa-malick/MALARIA_DETECTION

Résumé

Ce projet classe des images de cellules sanguines en deux catégories : cellule parasitée par Plasmodium, ou cellule saine. Trois architectures de réseaux de neurones convolutifs sont comparées sur le jeu de données NIH, qui contient 27 558 images.

Le modèle retenu est CNN_Deep. Sur le jeu de test, il atteint une accuracy de 96,78 % et une sensibilité de 94,65 %. La sensibilité est la métrique importante ici : elle mesure la proportion de cellules malades effectivement détectées.

Ce chiffre doit être lu avec prudence. Sur le jeu de validation, composé d'autres patients, la sensibilité du même modèle tombe à 89,46 %. L'écart entre les deux mesures atteint 5,2 points. La performance réelle dépend donc fortement des patients évalués. Le chapitre 7 revient sur ce point.

Le système est accompagné d'une interface web, d'une API REST, d'une image Docker et d'une suite de tests automatisés.

Mots-clés : apprentissage profond, réseaux convolutifs, paludisme, imagerie médicale, TensorFlow, Flask, Docker.

1. Contexte et objectifs

1.1 Le problème

Le paludisme est une maladie parasitaire transmise par le moustique anophèle. Il reste une cause majeure de mortalité en Afrique subsaharienne, et le Sénégal figure parmi les pays touchés.

Le diagnostic de référence se fait au microscope. Un technicien examine un frottis sanguin et cherche le parasite dans les globules rouges. Cette méthode est fiable mais lente. Elle demande un opérateur formé, et sa qualité varie selon l'expérience de celui-ci.

1.2 L'idée

Un réseau de neurones convolutif sait classer des images. On peut donc lui apprendre à distinguer une cellule parasitée d'une cellule saine, à partir d'exemples déjà étiquetés par des experts.

L'objectif n'est pas de remplacer le microscopiste. Il est de fournir une aide au tri, qui signale les cellules suspectes.

1.3 Objectifs du projet

- Construire une pipeline complète, du chargement des images à l'évaluation.
- Comparer trois architectures convolutives de complexité croissante.
- Mesurer la performance avec un protocole d'évaluation honnête.
- Exposer le modèle via une API et une interface web.
- Rendre le tout reproductible avec Docker et des tests automatisés.

2. Les données

2.1 Le jeu NIH

Le jeu de données provient de la National Library of Medicine des États-Unis. Il contient 27 558 images de cellules sanguines isolées, extraites de frottis minces colorés au Giemsa.

Il est parfaitement équilibré : 13 779 cellules parasitées et 13 779 cellules saines. Cet équilibre est confortable, car il évite d'avoir à corriger un déséquilibre de classes.

Caractéristique	Valeur
Nombre total d'images	27 558
Cellules parasitées	13 779
Cellules saines	13 779
Format	PNG, couleur
Taille d'entrée du réseau	64 x 64 pixels

Exemples d'images - Détection du Paludisme




Figure 1. Exemples d'images du jeu de données.

2.2 Une information cachée dans les noms de fichiers

Les noms de fichiers suivent un format précis, par exemple C116P77ThinF_IMG_20150930_171219_cell_110.png. Le préfixe C116P77 identifie le frottis, donc le patient.

Cette information est essentielle. Le jeu ne contient pas 27 558 prélèvements indépendants, mais les cellules de 200 patients seulement. Un même patient fournit entre 65 et 702 cellules.

Le projet compte 200 patients pour 27 558 images.

3. Le protocole d'évaluation

3.1 Pourquoi le découpage habituel est trompeur

La pratique courante consiste à mélanger toutes les images, puis à en tirer 70 % pour l'entraînement, 15 % pour la validation et 15 % pour le test.

Appliqué ici, ce découpage produit un problème grave. Comme un patient fournit des dizaines de cellules, ses cellules se retrouvent des deux côtés du découpage. La mesure effectuée sur ce projet est sans appel : 100 % des images de test proviennent de patients également présents à l'entraînement, et les 200 patients sont partagés.

Le modèle peut alors obtenir un bon score en reconnaissant un patient déjà vu, et non en reconnaissant le parasite. Le score mesuré ne dit plus ce qu'on croit qu'il dit.

3.2 Le découpage par patient

La correction consiste à découper par patient et non par image. Chaque patient appartient à un seul ensemble. Le modèle est ainsi évalué sur des patients qu'il n'a jamais vus, ce qui correspond à son usage réel.

Ensemble	Patients	Images	Part de cellules parasitées
Train	139	20 510	53,2 %
Validation	31	3 597	40,9 %
Test	30	3 451	40,7 %

C'est ce protocole qui est utilisé pour tous les résultats présentés dans ce rapport.

3.3 Les métriques retenues

La classe positive est la cellule parasitée. Ce choix a une conséquence directe sur le sens des métriques.

Métrique	Ce qu'elle mesure	Pourquoi elle compte
Sensibilité	Part des cellules malades détectées	Un manque signifie un malade non repéré
Spécificité	Part des cellules saines bien classées	Un manque signifie une fausse alerte
Précision	Part des alertes qui sont justes	Mesure la fiabilité d'une alerte
Accuracy	Part totale de bonnes réponses	Utile mais insuffisante seule

En dépistage, la sensibilité prime. Une fausse alerte entraîne un examen supplémentaire. Un malade non détecté rentre chez lui sans traitement.

4. Les architectures comparées

4.1 Principe d'un réseau convolutif

Un réseau convolutif analyse une image par petites zones. Un filtre de 3 x 3 pixels balaie l'image et réagit à un motif précis : un bord, une texture, une tache sombre.

Les premières couches détectent des motifs simples. Les couches suivantes combinent ces motifs pour former des formes plus complexes. C'est ce qui permet au réseau de reconnaître le parasite, qui apparaît comme une tache colorée dans le globule rouge.

Entre deux blocs de convolution, une couche de sous-échantillonnage réduit la taille de l'image. Le réseau perd du détail mais gagne en capacité à généraliser.

4.2 Les trois modèles

Modèle	Blocs de convolution	Particularité
CNN_Simple	2	Référence de base, peu de paramètres
CNN_Deep	3	Plus profond, plus de capacité
CNN_BN	3	Ajout de Batch Normalization

Les trois partagent la même entrée de 64 x 64 pixels en couleur et la même sortie : une valeur entre 0 et 1, interprétée comme la probabilité que la cellule soit saine.

4.3 Lutte contre le surapprentissage

Le surapprentissage survient quand le modèle mémorise les images d'entraînement au lieu d'apprendre à généraliser. Quatre mécanismes sont utilisés pour le limiter.

- Dropout : désactive au hasard une partie des neurones à chaque passage.
- Batch Normalization : stabilise les valeurs circulant entre les couches.
- Augmentation des données : rotations, décalages, symétries et zooms.
- Arrêt anticipé : stoppe l'entraînement dès que la validation se dégrade.

L'augmentation est appliquée uniquement aux données d'entraînement. Les jeux de validation et de test restent intacts, sans quoi la mesure serait faussée.

5. L'entraînement

Les trois modèles sont entraînés dans les mêmes conditions, avec la même graine aléatoire, ce qui rend la comparaison équitable et le run reproductible.

Paramètre	Valeur
Optimiseur	Adam

Fonction de coût	Binary crossentropy
Taille de lot	32
Époques maximum	20
Graine aléatoire	42

5.1 Les callbacks

Callback	Rôle
EarlyStopping	Arrête l'entraînement après 5 époques sans progrès
ModelCheckpoint	Enregistre le modèle à son meilleur état
ReduceLROnPlateau	Diminue le pas d'apprentissage en cas de stagnation

Les trois callbacks surveillent la même grandeur, la perte de validation. Ce détail évite une incohérence classique : si l'arrêt anticipé et la sauvegarde suivaient des critères différents, le fichier enregistré ne correspondrait pas au modèle évalué.

5.2 Déroulement observé

Modèle	Époques effectuées	Meilleure accuracy en validation
CNN_Simple	15	93,61 %
CNN_Deep	19	94,16 %
CNN_BN	9	93,77 %

Les écarts d'époques entre modèles viennent de l'arrêt anticipé, qui se déclenche à des moments différents selon la convergence.




Figure 2. Courbes d'apprentissage du modèle CNN_Deep.

6. Résultats

Le modèle est choisi sur le jeu de validation. Le jeu de test ne sert qu'à la mesure finale. Choisir le modèle sur le test reviendrait à s'auto-attribuer une bonne note.

6.1 Performances sur le jeu de test

Modèle	Accuracy	Sensibilité	Spécificité	Précision	F1
CNN_Simple	96,78 %	95,44 %	97,71 %	96,61 %	96,02 %
CNN_Deep (retenu)	96,78 %	94,65 %	98,24 %	97,36 %	95,99 %
CNN_BN	96,12 %	94,51 %	97,22 %	95,88 %	95,19 %




Figure 3. Comparaison des trois modèles sur le jeu de test.

6.2 Lecture de la matrice de confusion

La matrice de confusion détaille les erreurs. La case importante est celle des cellules parasitées classées comme saines : ce sont les malades manqués.




Figure 4. Matrice de confusion du modèle CNN_Deep.

6.3 Les trois modèles se valent

L'écart d'accuracy entre le meilleur et le moins bon modèle est de 0,7 point. Chaque architecture n'a été entraînée qu'une fois. Un tel écart ne permet pas de conclure qu'une architecture est supérieure aux autres.

La conclusion utile est inverse de celle attendue : la profondeur supplémentaire n'apporte rien sur ce problème. À performance égale, le modèle le plus léger est préférable.

7. Limites

Cette section est volontairement détaillée. Un résultat dont on ne connaît pas les limites n'est pas exploitable.

7.1 L'estimation est instable

Mesure	Jeu de validation	Jeu de test
Accuracy	93,94 %	96,78 %
Sensibilité	89,46 %	94,65 %

Il s'agit du même modèle, du même entraînement, du même protocole. Seuls les patients changent. L'écart de sensibilité atteint 5,2 points.

Avec une trentaine de patients par ensemble, un chiffre unique n'est pas fiable. La formulation honnête est que la sensibilité du modèle se situe entre 89 % et 95 % selon les patients.

Une validation croisée par groupes de patients donnerait une moyenne et un écart-type. Elle n'a pas été réalisée, son coût étant d'environ cinq entraînements complets.

7.2 Le découpage par image masquait cette instabilité

Avec l'ancien découpage, validation et test donnaient des résultats quasiment identiques. Cette concordance ressemblait à de la robustesse. Elle n'en était pas : les deux ensembles contenaient les mêmes patients, ils ne pouvaient que s'accorder. La fuite ne gonflait pas seulement le score, elle dissimulait la dispersion réelle.

7.3 Autres limites

- Le modèle manque une part non négligeable des cellules parasitées, ce qui est incompatible avec un usage clinique.
- La validation se limite au jeu NIH : frottis minces, coloration Giemsa, images réduites à 64 x 64 pixels. Rien ne garantit la transposition à d'autres protocoles ou d'autres microscopes.
- Chaque architecture n'a été entraînée qu'une seule fois.
- Aucune validation clinique n'a été conduite.

7.4 Avertissement

Ce travail est un exercice académique. Il ne constitue pas un dispositif médical et ne remplace pas un diagnostic posé par un professionnel de santé.

8. Application et déploiement

8.1 L'API

Route	Méthode	Rôle
/	GET	Interface web
/predict	POST	Analyse une image et retourne la prédiction
/metrics	GET	Métriques des modèles au format JSON
/health	GET	État du service

8.2 Traitement d'une image

L'image envoyée est validée, redimensionnée en 64 x 64 pixels, puis normalisée. Le modèle retourne une probabilité, convertie en verdict.

L'image est supprimée du serveur immédiatement après l'analyse. Une taille maximale est imposée. Ces deux points évitent la saturation du disque et la conservation involontaire de données personnelles.

8.3 L'interface

L'utilisateur dépose une image de cellule et obtient un verdict accompagné de la confiance du modèle. L'avertissement rappelant que l'outil n'est pas un dispositif médical est affiché en permanence au-dessus de la zone d'analyse.




Figure 5. Analyse d'une cellule parasitée dans l'interface web.

L'interface expose également le tableau comparatif des trois modèles, alimenté par le fichier de métriques. Les colonnes reprennent la sensibilité et la spécificité, et non des métriques génériques.




Figure 6. Comparaison des modèles telle qu'affichée par l'application.

8.4 Déploiement

L'application est empaquetée dans une image Docker et servie par gunicorn. Le jeu de données est exclu de l'image, qui n'a besoin que du modèle entraîné. Le conteneur ne s'exécute pas en tant que superutilisateur.

L'application est déployée et accessible publiquement à l'adresse suivante : <https://deep-learning-malaria-detection-znf2.onrender.com/>

9. Tests et qualité

Le projet est couvert par une suite de tests automatisés, exécutée à chaque modification par une chaîne d'intégration continue.

Fichier	Ce qui est vérifié
test_models.py	Formes de sortie et structure des trois réseaux
test_preprocessing.py	Découpages, et surtout l'étanchéité du découpage par patient
test_utils.py	Préparation d'image et format des prédictions
test_api.py	Routes, rejets d'upload et suppression des fichiers

Le test le plus important vérifie qu'aucun patient n'apparaît dans deux ensembles à la fois. Il empêche la fuite décrite au chapitre 3 de revenir sans être remarquée.

Les tests s'exécutent sans le jeu de données ni les modèles entraînés, ce qui permet de les lancer automatiquement sur un serveur d'intégration.

10. Conclusion

Le projet aboutit à un système fonctionnel. Le modèle CNN_Deep atteint 96,78 % d'accuracy et 94,65 % de sensibilité sur des patients jamais vus à l'entraînement.

L'apport principal de ce travail n'est pas le score. Il est la mise en évidence d'un biais méthodologique : le découpage habituel des données mélange les patients entre entraînement et test, ce qui produit des chiffres flatteurs et masque la variabilité réelle entre patients.

Corriger ce biais a changé les conclusions du projet. Le modèle retenu n'est plus le même, l'écart entre architectures s'est révélé non significatif, et la performance s'exprime désormais comme un intervalle plutôt que comme un chiffre unique.

10.1 Perspectives

- Validation croisée par groupes de patients, pour une moyenne et un écart-type.
- Ajustement du seuil de décision pour privilégier la sensibilité.
- Transfer learning à partir d'un modèle pré-entraîné.
- Grad-CAM, pour visualiser les zones observées par le réseau.
- Évaluation sur un jeu de données issu d'un autre laboratoire.

Références

- National Library of Medicine. Malaria Datasets. <https://ceb.nlm.nih.gov/repositories/malaria-datasets/>
- Rajaraman S. et collaborateurs. Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection. PeerJ, 2018.
- Organisation mondiale de la santé. World Malaria Report.

- Documentation TensorFlow et Keras. <https://www.tensorflow.org/>
- Documentation scikit-learn. <https://scikit-learn.org/>